

Telco Churn · Projeto Completo · v2.1

MACHINE LEARNING CANVAS

3 Etapas Concluídas

LogisticRegression (prod) + MLP PyTorch (servido pela API v2.1.0) · 137 testes

?

PREDICTION TASK

Tipo: Classificação binária (churn/no-churn)

Input: 19 features por cliente (JSON payload)

Output: probabilidade de churn [0.0 – 1.0]

Classe positiva: Churn = 1 (26.54% da base)

Desbalanceamento: class_weight='balanced'

👤

DECISIONS

Score → lista priorizada de risco para retenção

Callcenter acessa risco do cliente durante a ligação

Threshold padrão: prob > 0.5 → alerta retenção

Alta prioridade: prob > 0.7 → ação imediata

Campanha proativa semanal via /predict_batch

★

VALUE PROPOSITION

Quem: Time de Retenção & Agentes de Callcenter

Objetivo: identificar clientes em risco antes do cancelamento

Benefício: reduzir churn 15% · economizar ~R\$ 5M/ano

Interface: API REST · POST /predict · resposta JSON < 2ms

ROI: custo de retenção 5× menor que aquisição de novo cliente

📄

DATA COLLECTION

7.043 registros históricos — snapshot XLSX

Split estratificado 80/20, seed=42 (reproduzível)

11 NaN em TotalCharges → imputados com 0

Schema Pandera — 12 verificações automáticas

Holdout: 1.409 clientes (20%) para avaliação

📁

DATA SOURCES

Telco Customer Churn (arquivo XLSX)

19 features utilizadas (pós leakage fix v2.0)

Numéricas (3): tenure · monthly_charges · total_charges

Catégoricas (16): contract · internet · tech_support...

Leakage fix: 11 colunas removidas (Churn Score, CLTV...)

✓

OFFLINE EVALUATION — TEST SET: 1.409 CLIENTES

AUC-ROC (meta ≥ 0.80)

0.848

✓

Recall (meta ≥ 55%)

58.3%

✓

Accuracy (meta ≥ 78%)

80.34%

✓

PR-AUC

0.644

✓

F1-Score (meta ≥ 0.55)

0.611

✓

Specificity

88.3%

✓

⚡

MAKING PREDICTIONS

Real-time: POST /predict (CRM/callcenter)

Batch: POST /predict_batch (campanhas noturnas)

Latência P95: < 2ms — meta < 100ms

CPU inference · FastAPI porta 8000 · Docker

Header de diagnóstico: X-Process-Time-Ms

⚙️

BUILDING MODELS

Melhor (LR):

AUC-ROC 0.848, F1 0.611, Accuracy 80.34%

Servido pela API:

MLP PyTorch 19→128→64→32→2 (13.410 params), AUC-ROC 0.833, F1 0.583

MLflow tracking: 83+ runs

Early stopping patience=10

Serialização: .pkl (sklearn + preprocessor) · .pt (pytorch)

Retraining: se PSI > 0.2 ou degradação mensal

☰

FEATURES

Numéricas (3):

StandardScaler — tenure · monthly_charges · total_charges

Catégoricas (16):

OrdinalEncoder — contract · internet_service · tech_support · payment_method...

Todas disponíveis no momento da predição (sem feature store)

Leakage fix v2.0: 11 colunas derivadas do target removidas

📍

LIVE MONITORING

CRÍTICOS — ROLLBACK IMEDIATO

WARNINGS — AÇÃO PLANEJADA

MÉTRICAS DE PERFORMANCE

QUALIDADE & TESTES