

Visão Geral

Performance

Arquitetura

Features

Limitações

Validação

Datasets

Deployment

Monitoramento

Governança

📌 1. Visão Geral do Modelo

Objetivo: Identificar clientes de telecomunicações com risco de cancelar o serviço (churn), possibilitando ações proativas de retenção antes da perda.

7,043

CLIENTES

Dataset de treinamento

19

FEATURES

3 numéricas + 16 categóricas

26.5%

TAXA DE CHURN

1.869 clientes

0.848

AUC-ROC

Melhor modelo (LogReg)

<2ms

LATÊNCIA P99

Predição em tempo real

135

TESTES

100% passando

Contexto de Negócio

Problema

Operadoras de telecomunicações perdem clientes em ritmo acelerado. Cada cliente perdido representa ~R\$500 de receita anual. O custo de adquirir um novo cliente é 5x maior que reter um existente. Identificar o risco antecipadamente permite campanhas de retenção direcionadas.

INDICADOR

VALOR

Taxa de churn anual

26.5%

Impacto anual estimado

R\$ 9M em receita

Objetivo de redução

15% em 6 meses

ROI estimado

Payback em 3 meses

Custo por falso negativo

R\$ 500 (cliente perdido)

Custo por falso positivo

R\$ 100 (oferta desnecessária)

📊 2. Performance dos Modelos

Comparativo — Test Set (1,409 clientes)

MODELO

ACCURACY

F1

AUC-ROC

PR-AUC

STATUS

DummyClassifier (baseline)

73.46%

0.000

0.500

0.265

Referência

LogisticRegression

80.34%

0.611

0.848

0.644

Melhor

RandomForest

79.20%

0.571

0.839

0.627

Competitivo

MLP PyTorch (Etapa 2 — serviço pela API)

79.22%

0.583

0.833

0.592

Competitivo

Nota sobre Data Leakage

Versões anteriores apresentavam accuracy artificial de 100% por incluir Churn Score, Churn Reason e CLTV como features. Após correção, as métricas acima refletem performance realista em dados não vistos. Veja seção Limitações.

Métricas Detalhadas — LogisticRegression

MÉTRICA

VALOR

REFERÊNCIA

STATUS

Accuracy

80.34%

> 78%

✓ OK

Precision (Churn)

0.643

> 0.60

✓ OK

Recall (Sensitivity)

0.583

> 0.55

✓ OK

F1-Score

0.611

> 0.55

✓ OK

AUC-ROC

0.848

> 0.80

✓ Bom

PR-AUC

0.644

> 0.55

✓ Bom

Specificity

88.3%

—

✓ Alto

Matriz de Confusão — LogisticRegression (n=1,409)

PREDITO: NÃO CHURN

PREDITO: CHURN

REAL: NÃO CHURN

914
TN — Certo ✓

121
FP — Falso alarme

REAL: CHURN

156
FN — Perda Δ

218
TP — Detectado ✓

Impacto Financeiro (test set)

CATEGORIA

QTD

CUSTO UNIT

TOTAL

Obs.

✓ TP — Churns detectados

218

R\$ 300 (oferta)

+R\$ 65,400

Receita retida

✗ FN — Churns perdidos

156

R\$ 500 (LTV)

-R\$ 78,000

Perda não evitada

⚠ FP — Falsos alarmes

121

R\$ 100 (custo campanha)

-R\$ 12,100

Custo desnecessário

Resultado líquido estimado

-R\$ 24,700

Sem modelo: -R\$ 187,000

🗣️ 3. Arquitetura do Modelo

MLP PyTorch — Etapa 2

19

Input features

→

128

Hidden 1
(ReLU, Dropout)

→

64

Hidden 2
(ReLU, Dropout)

→

32

Hidden 3
(ReLU, Dropout)

→

2

Output (softmax)

PARÂMETRO

VALOR

Total de parâmetros

13,410

Optimizer

Adam (lr=1e-3, weight_decay=1e-4)

Loss

CrossEntropyLoss (class_weight balanced)

Batch size

64

Early stopping

patience=10 épocas

Formato salvo

modelo/mlp_etapa2.pt

Input dim (runtime)

19 (carregado via metadados)

Pipeline de Pré-processamento

TIPO

COLUNAS

TRANSFORMAÇÃO

Númericas (3)

Tenure Months, Monthly Charges, Total Charges

StandardScaler (persistido em modelo/preprocessor.pkl)

Catégoricas (16)

Gender, Senior Citizen, Partner, Dependents, Phone Service, Multiple Lines, Internet Service, Online Security, Online Backup, Device Protection, Tech Support, Streaming TV, Streaming Movies, Contract, Paperless Billing, Payment Method

LabelEncoder por coluna (mesmos encoders usados no treino)

Target

Churn Value

LabelEncoder → {0, 1}

API FastAPI v2.1.0

ENDPOINT

MÉTODO

DESCRIÇÃO

/health

GET

Status da API e modelo carregado

/info

GET

Arquitetura e parâmetros do modelo

/predict

POST

Predição individual com probabilidades

/predict_batch

POST

Predição em lote

/metrics

GET

Estatísticas de uso em runtime

🔍 4. Features Mais Importantes

Importância relativa estimada por coeficientes do LogisticRegression normalizado.

1

Contract Type

15.2%

Mito: maior churn vs 3% em contrato > 2 anos

2

Tenure

12.8%

Clientes <3 meses: 50% churn vs >24 meses: 5%

3

Internet Service

10.9%

Fiber Optic: 42% churn vs 7% sem internet

4

Tech Support

8.3%

Sem suporte: 40% churn vs 15% com suporte

5

Monthly Charges

7.2%

Alta correlação com tipo de contrato e serviços

6

Online Security

6.1%

Sem serviço: 41% churn vs 14% com serviço

7

Payment Method

5.0%

Parcela eletrônica associada a maior churn

Features Removidas (Data Leakage)

11 colunas removidas por causar leakage do target:
CustomerID, Churn Score, Churn Reason, CLTV, Zip Code, Latitude, Longitude, City, Lat Long, Count, Churn Label (target apenas).

⚠️ 5. Limitações e Riscos

Limitações Conhecidas

1. Data Leakage — Resolvido

✓ Corrigido na v2.0.0
Versões anteriores incluíam Churn Score, Churn Reason e CLTV que são derivados diretamente do target, causando AUC-ROC artificial de ~1.0. Após correção, o modelo usa apenas features disponíveis antes do evento de churn. Métricas realistas: AUC-ROC 0.848.

2. Data Drift

⚠️ Risco Médio
Comportamento do cliente muda ao longo do tempo (novos planos, sazonalidade, crises econômicas). O modelo foi treinado em dados de um período específico. Recomendado: verificação semanal de distribuição por PSI, retreinamento mensal se PSI > 0.2.

3. Desbalanceamento de Classes (26.5% minority)

🛡️ Mitigado
Aplicado class_weight="balanced" no LogisticRegression e pesos ponderados no MLP. Recall de 58.3% reflete custo de falsos negativos. Para operações de alto risco, considere limiar de decisão abaixo de 0.5.

4. Generalização Geográfica

⚠️ Risco
Dataset representa clientes de uma única operadora em uma região. Performance pode degradar em geografias com perfil de consumo distinto.

Avaliação de Fairness

DIMENSÃO

ACHADO

RISCO

AÇÃO RECOMENDADA

Gênero

Performance similar entre IMF

Baixo

Monitorar mensalmente

Faixa etária

Senior Citizens: menor precision

Médio

Desagregar métricas por grupo

Renda (proxy via charges)

Monthly Charges alta correlação

Muito

Auditoria de fairness trimestral

Tipo de contrato

Clientes pré-pago sub-representados

Médio

Expandir dataset de treinamento

🔧 6. Validação e Testes

135

TESTES TOTAIS

100% passando

8

SUITES

API, Data, MLP, E2E...

57%

COBERTURA

Métricas core >90%

Suites de Testes

SUITE

ARQUIVO

TESTES

COBERTURA

Config + Logging

test_config_logging.py

34

100%

DataLoader + Preprocessor

test_data_expanded.py

22

96%

Schema Panderas

test_schema_expanded.py

12

100%

MLP Architecture + Training

test_mlp_etapa2.py

21

100%

Baselines (3 modelos)

test_modela_expanded.py

15

94%

FastAPI Endpoints

test_api_etapa3.py

18

80%

MLflow Tracking

test_mlflow.py

11

89%

Integração E2E

test_integration_e2e.py

~10

—

Total

135+

Todos passando ✓

Validação de Schema (Panderas)

12 verificações automáticas por execução:
- tipos numéricos (tenure, id, charges, id) - target binário {0,1} - churn rate entre 10-50% - zero valores ausentes, zero duplicatas, ausência de colunas de leakage, valores catégoricos válidos, mínimo 5.000 linhas, mínimo 15 features.

📁 7. Dataset

PROPRIEDADE

VALOR

Arquivo fonte

data/raw/telco_customer_churn.xlsx

Total de registros

7,043 clientes

Split treino/teste

80/20 estratificado — 5,634 / 1,409

Features (pós leakage fix)

19 (3 numéricas + 16 catégoricas)

Features removidas

11 colunas de leakage + identificadores

Distribuição target

73.46% No-Churn (5,174) / 26.54% Churn (1,869)

Qualidade dos dados

0 duplicatas - 11 NaN em TotalCharges (imputados) - sem anomalias críticas

Rastreabilidade

MLflow: experimento telco-churn-prediction (83+ runs)

Features Utilizadas

TIPO

COLUNAS

Númericas (3)

tenure - monthly_charges - total_charges

Catégoricas (16)

gender - senior_citizen - partner - dependents - phone_service - multiple_lines - internet_service - online_security - online_backup - device_protection - tech_support - streaming_tv - streaming_movies - contract - paperless_billing - payment_method

🚀 8. Deployment

Decisão Arquitetural: Real-Time vs Batch

✓ Arquitetura escolhida: Real-Time API (inferência online)
Agentes de atendimento precisam do risco do cliente durante a ligação. Latência de horas (batch) inviabiliza o caso de uso operacional. O endpoint /predict_batch cobre campanhas noturnas sem orquestração adicional.

CRITÉRIO

REAL-TIME ✓ (ESCOLHIDO)

BATCH

Latência

< 100ms

Horas (agendado)

Caso de uso

CRM / callcenter ao vivo

Relatório noturno / DW

Volume do projeto

~200 contatos/dia ✓

Útil acima de 1M/dia

Complexidade

Baixa — REST simples

Alta — Airflow/Spark

Freshness

Imediata

Defasagem horas/dias

Integração

HTTP direto para qualquer sistema

Requer pipeline de dados

Infraestrutura

COMPONENTE

TECNOLOGIA

DETALHE

API

FastAPI 0.100+

Uvicorn ASGI, porta 8000

Modelo (Scikit-Learn)

Pickle.pkl

<2 MB, CPU-only

Modelo (MLP)

PyTorch .pt

13.410 parâms, CPU inference

Rastreamento

MLflow

Backend local (file://) ou remoto

Container

Docker + docker-compose

API + MLflow UI (opcional)

SLOs de Produção

LATÊNCIA P99

< 100ms

Predição individual

DISPONIBILIDADE

99.5%

Meta mensal

ACCURACY MÍNIMA

78%

Alerta se abaixo

THROUGHPUT

1k req/s

1k req/core

Checklist de Deploy

✓ Modelos treinados e validados

✓ Performance verificada no test set

✓ 137 testes automatizados passando

✓ Schema Panderas validado

✓ Model Card documentado

✓ Linting nuff zero erros

✓ MLflow tracking ativo (83 runs)

✓ Latência monitorada (middleware)

🏆 Code review aprovado

🏆 Deploy em cloud (AWS/Azure/GCP)

🏆 Smoke tests em produção

🏆 Equipe treinada

📊 9. Monitoramento

Métricas em Tempo Real

✓ Implementado na API
Header X-Trace-ID=... em todas as respostas - endpoint /metrica com contadores de requisições, acertos e erros - logging estruturado com REDISIO /psch → STATUS (28s).

Detecção de Data Drift

MÉTRICA

MÉTODO

THRESHOLD

FREQUÊNCIA

Feature drift

PSI (Population Stability Index)

PSI > 0.2 = retraining

Semanal

Prediction drift

KS-test na distribuição de scores

p-value < 0.05

Diário

Model accuracy

Comparação com ground-truth acumulado

< 78% = alerta

Mensal

Política de Alertas

NÍVEL

CONDIÇÃO

SIA DE RESPOSTA

CRÍTICO

Accuracy < 78% - Latência P99 > 1s - API down

Imediato — rollback automático

WARNING

PSI > 0.2 em feature-chave - Drift detectado

24h — agendar retreinamento

INFO

Relatório diário de performance

Review semanal

Ciclo de Retreinamento

Recomendação:
Retreinamento mensal com dados dos últimos 6 meses em janela deslizando. Validar novo modelo contra holdout antes de promover para produção. Versionamento obrigatório no MLflow.

📋 10. Governança e Ética

Princípios de IA Responsável

PRINCÍPIO

IMPLEMENTAÇÃO

STATUS

Transparência

Model Card público, documentação de features e limitações

✓ OK

Fairness

Testado em gender e senior_citizen; class_weight balanceado

✓ OK

Privacidade

Sem PII retido; CustomerID removido do modelo

✓ OK

Accountability

MLflow tracking de todos os experimentos; versão rastreável

✓ OK

Segurança

Validação Pydantic na API; sem injeção de dados brutos

✓ OK

LGPD/Compliance

Dados anonimizados; sem retenção de PII em logs

⚠️ Verificar

Papeis e Responsabilidades

PAPEL

RESPONSABILIDADE

Data Science

Treinamento, validação, análise de bias, documentação técnica

DevOps / MLOps

Definição de SLOs, comunicação com stakeholders, priorização de retraining

ProdOps / MLops

Infraestrutura, CI/CD, monitoramento, resposta a incidentes

Legal / Compliance

LGPD, consentimento para uso de dados, auditoria de fairness

Histórico de Versões

VERSÃO

DATA

MUDANÇA PRINCIPAL

1.0.0

2026-03

EDA + Baselines (LogReg, RF, Dummy) — com data leakage

1.5.0

2026-04

MLP PyTorch adicionado (Etapa 2)

2.0.0

2026-04

Correção crítica de data leakage - FastAPI v2 - 135 testes - Monitoring

2.1.0

2026-05

API com preprocessor real (StandardScaler + LabelEncoders persistidos) - lifespan handler - 137 testes

Model Card — Telco Churn Prediction v2.1.0

STATUS: ● Production Ready