

MODEL CARD V2.0

Telco Churn Prediction

Sistema de predição de risco de churn para operadoras de telecomunicações

STATUS

Production Ready

VERSÃO

2.0.0

DATA

Abril 2026

FRAMEWORK

PyTorch 2.0 + Scikit-Learn

API

FastAPI v2.0.0

TESTES

135 passando

Visão Geral

Performance

Arquitetura

Features

Limitações

Validação

Datasets

Deployment

Monitoramento

Governança

1. Visão Geral do Modelo

Objetivo: Identificar clientes de telecomunicações com risco de cancelar o serviço (churn), possibilitando ações proativas de retenção antes da perda.

7,043

CLIENTES

Dataset de treinamento

19

FEATURES

3 numéricas + 16 categóricas

26.5%

TAXA DE CHURN

1,869 clientes

0.848

AUC-ROC

Melhor modelo (LogReg)

<2ms

LATÊNCIA P90

Predição em tempo real

135

TESTES

100% passando

Contexto de Negócio

Problema

Operadoras de telecomunicações perdem clientes em ritmo acelerado. Cada cliente perdido representa ~R\$500 de receita anual. O custo de adquirir um novo cliente é 5x maior que reter um existente. Identificar o risco antecipadamente permite campanhas de retenção direcionadas.

INDICADOR	VALOR
Taxa de churn atual	26.5%
Impacto anual estimado	R\$ 5M em receita
Objetivo de redução	15% em 6 meses
ROI estimado	Payback em 3 meses
Custo por falso negativo	R\$ 500 (cliente perdido)
Custo por falso positivo	R\$ 100 (oferta desnecessária)

2. Performance dos Modelos

Comparativo — Test Set (1,409 clientes)

MODELO	ACCURACY	F1	AUC-ROC	PRAUC	STATUS
DummyClassifier (baseline)	73.46%	0.000	0.500	0.285	Referência
LogisticRegression	80.34%	0.611	0.848	0.644	Melhor
▲ Modelo selecionado para produção — melhor AUC-ROC e Recall					
RandomForest	79.35%	0.565	0.834	0.627	Competitivo
MLP PyTorch (Etapa 2)	79.28%	0.556	0.837	0.649	Competitivo

Nota sobre Data Leakage

Versões anteriores apresentavam accuracy artificial de 100% por incluir Churn_Score, Churn_Reason e CLTV como features. Após correção, as métricas acima refletem performance realista em dados não vistos. Veja seção Limitações.

Métricas Detalhadas — LogisticRegression

MÉTRICA	VALOR	REFERÊNCIA	STATUS
Accuracy	80.34%	> 78%	✓ OK
Precision (Churn)	0.643	> 0.60	✓ OK
Recall (Sensitivity)	0.583	> 0.55	✓ OK
F1-Score	0.611	> 0.55	✓ OK
AUC-ROC	0.848	> 0.80	✓ Bom
PRAUC	0.644	> 0.55	✓ Bom
Specificity	88.3%	—	✓ Alto

Matriz de Confusão — LogisticRegression (n=1,409)

	PREDITO: NÃO CHURN	PREDITO: CHURN
REAL: NÃO CHURN	914 TN — Correto ✓	121 FP — Falso alarme
REAL: CHURN	156 FN — Falso Δ	218 TP — Correto ✓

Impacto Financeiro (test set)

CATEGORIA	QTD	CUSTO UNIT.	TOTAL	OBS.
✓ TP — Churns detectados	218	R\$ 300 (oferta)	+R\$ 65,400	Receita retida
✗ FN — Churns perdidos	156	R\$ 500 (LTV)	-R\$ 78,000	Perda não evitada
⚠ FP — Falsos alarmes	121	R\$ 100 (custo campanha)	-R\$ 12,100	Custo desnecessário
Resultado líquido estimado			-R\$ 24,700	Sem modelo: -R\$ 187,000

3. Arquitetura do Modelo

MLP PyTorch — Etapa 2

19

Input Feature

→

128

Hidden 1
(BN + ReLU + Dropout)

→

64

Hidden 2
(BN + ReLU + Dropout)

→

32

Hidden 3
(BN + ReLU + Dropout)

→

2

Output Softmax

PARÂMETRO	VALOR
Total de parâmetros	13,410
Optimizer	Adam (lr=1e-3, weight_decay=1e-4)
Loss	CrossEntropyLoss (class_weight balanced)
Batch size	64
Early stopping	patience=10 épocas
Formato salvo	models/mlp_etapa2.pt
Input dim (runtime)	19 (carregado via metadata)

Pipeline de Pré-processamento

TIPO	COLUNAS	TRANSFORMAÇÃO
Númericas (3)	tenure, monthly_charges, total_charges	StandardScaler
Categóricas (16)	gender, internet_service, contract, ...	OrdinalEncoder (handle_unknown=-1)
Target	Churn Label	LabelEncoder → {0, 1}

API FastAPI v2.0.0

ENDPOINT	MÉTODO	DESCRIÇÃO
/health	GET	Status da API e modelo carregado
/info	GET	Arquitetura e parâmetros do modelo
/predict	POST	Predição individual com probabilidades
/predict_batch	POST	Predição em lote
/metrics	GET	Estatísticas de uso em runtime

4. Features Mais Importantes

Importância relativa estimada por coeficientes do LogisticRegression normalizado.

1

Contract Type

15.2%

Mês-a-mês: 42% churn vs 3% em contrato > 2 anos

2

Tenure

12.8%

Clientes <3 meses: 50% churn; >24 meses: 5%

3

Internet Service

10.5%

Fiber Optic: 40% churn vs 7% sem internet

4

Tech Support

8.3%

Sem suporte: 40% churn vs 15% com suporte

5

Monthly Charges

7.2%

Alta correlação com tipo de contrato e serviços

6

Online Security

6.1%

Sem serviço: 41% churn vs 14% com serviço

7

Payment Method

5.0%

Bolêto eletrônico associado a maior churn

Features Removidas (Data Leakage)

11 colunas removidas por causar leakage do target:

CustomerID, Churn Score, Churn Reason, CLTV, Zip Code, Latitude, Longitude, City, Lat Long, Count, Churn Label (target asens).

5. Limitações e Riscos

Limitações Conhecidas

1. Data Leakage — Resolvido

✓ Corrigido na v2.0.0

Versões anteriores incluíam Churn_Score, Churn_Reason e CLTV que são derivados diretamente do target, causando AUC-ROC artificial de ~1.0. Após correção, o modelo usa apenas features disponíveis antes do evento de churn. Métricas realistas: AUC-ROC 0.848.

2. Data Drift

▲ Risco Médio

Comportamento do cliente muda ao longo do tempo (novos planos, sazonalidade, crises econômicas). O modelo foi treinado em dados de um período específico. Recomendado: verificação semanal de distribuição por PSI; retreinamento mensal se PSI > 0.2.

3. Desbalanceamento de Classes (26.5% minority)

■ Mitigado

Aplicado class_weight="balanced" no LogisticRegression e pesos ponderados no MLP. Recall de 58.3% reflete custo de falsos negativos. Para operações de alto risco, considerar limiar de decisão abaixo de 0.5.

4. Generalização Geográfica

▲ Risco

Dataset representa clientes de uma única operadora em uma região. Performance pode degradar em geografias com perfis de consumo distintos.

Avaliação de Fairness

DIMENSÃO	ACHADO	RISCO	AÇÃO RECOMENDADA
Gênero	Performance similar entre M/F	Baixo	Monitorar mensalmente
Faixa etária	Senior Citizens: menor precisão	Médio	Desagregar métricas por grupo
Renda (proxy via charges)	Monthly Charges alta correlação	Médio	Auditoria de fairness trimestral
Tipo de contrato	Clientes pré-pago sub-representados	Médio	Expandir dataset de treinamento

6. Validação e Testes

135

TESTES TOTAIS

100% passando

8

SUÍTES

API, Data, MLP, E2E...

57%

COBERTURA

Módulos core >90%

Suítes de Testes

SUÍTE	ARQUIVO	TESTES	COBERTURA
Config + Logging	test_config_logging.py	34	100%
DataLoader + Preprocessor	test_data_expanded.py	22	98%
Schema Pandera	test_schema_pandera.py	12	100%
MLP Architecture + Training	test_mlp_etapa2.py	21	100%
Baselines (3 modelos)	test_models_expanded.py	15	94%
FastAPI Endpoints	test_api_etapa3.py	18	80%
MLflow Tracking	test_mlflow.py	11	89%
Integração E2E	test_integration_e2e.py	~10	—
Total		135+	Todos passando ✓

Validação de Schema (Pandera)

✓ 12 verificações automáticas por execução:

ranges numéricos (tenure ≥0, charges ≥0), target binário {0,1}, churn rate entre 10-50%, zero valores ausentes, zero duplicatas, ausência de colunas de leakage, valores categóricos válidos, mínimo 5.000 linhas, mínimo 15 features.

7. Dataset

PROPRIEDADE	VALOR
Arquivo fonte	data/raw/telco_customer_churn.xlsx
Total de registros	7,043 clientes
Split treino/teste	80/20 estratificado — 5,634 / 1,409
Features (pós leakage fix)	19 (3 numéricas + 16 categóricas)
Features removidas	11 colunas de leakage + identificadores
Distribuição target	73.46% No-Churn (5,174) · 26.54% Churn (1,869)
Qualidade dos dados	0 duplicatas · 11 NaN em TotalCharges (imputados) · sem anomalias críticas
Rastreabilidade	MLflow: experimento telco-churn-prediction (83+ runs)

Features Utilizadas

TIPO	COLUNAS
Númericas (3)	tenure · monthly_charges · total_charges
Categóricas (16)	gender · senior_citizen · partner · dependents · phone_service · multiple_lines · internet_service · online_security · online_backup · device_protection · tech_support · streaming_tv · streaming_movies · contract · paperless_billing · payment_method

8. Deployment

Decisão Arquitetural: Real-Time vs Batch

✓ Arquitetura escolhida: Real-Time API (inferência online)

Agentes de atendimento precisam do risco do cliente durante a ligação. Latência de horas (batch) inviabiliza o caso de uso operacional. O endpoint /predict_batch cobre campanhas noturnas sem orquestração adicional.

CRITÉRIO	REAL-TIME ✓ (ESCOLHIDO)	BATCH
Latência	< 100ms	Horas (agendado)
Caso de uso	CRM / callcenter ao vivo	Relatório noturno / DW
Volume do projeto	~200 contatos/dia ✓	Útil acima de 1M/dia
Complexidade	Baixa — REST simples	Alta — Airflow/Spark
Freshness	Imediata	Defasagem horas/dias
Integração	HTTP direto para qualquer sistema	Requer pipeline de dados

Infraestrutura

COMPONENTE	TECNOLOGIA	DETALHE
API	FastAPI 0.100+	Uvicorn ASGI, porta 8000
Modelo (Scikit-Learn)	Pickle .pkl	<2 MB, CPU-only
Modelo (MLP)	PyTorch .pt	13,410 params, CPU inference
Rastreamento	MLflow	Backend local file://mlruns
Container	Docker + docker-compose	API + MLflow UI (opcional)

SLOs de Produção

LATÊNCIA P95

< 100ms

Predição individual

DISPONIBILIDADE

99.5%

Meta mensal

ACCURACY MÍNIMA

78%

Alerta se abaixo

THROUGHPUT

1k req/s

CPU single-core

Checklist de Deploy

✓ Modelos treinados e validados

✓ Performance verificada no test set

✓ 135 testes automatizados passando

✓ Schema Pandera validado

✓ Model Card documentado

✓ Linting ruft zero erros

✓ MLflow tracking ativo (83 runs)

✓ Latência monitorada (middleware)

🔧 Code review aprovado

🔧 Deploy em cloud (AWS/Azure/GCP)

🔧 Smoke tests em produção

🔧 Equipe treinada

9. Monitoramento

Métricas em Tempo Real

✓ Implementado na API:

Header X-Process-Time-Ms em todas as respostas · endpoint /metrics com contadores de requisições, acertos e erros · logging estruturado com METRIC /path → STATUS (20ms).

Deteção de Data Drift

MÉTRICA	MÉTODO	THRESHOLD	FREQUÊNCIA
Feature drift	PSI (Population Stability Index)	PSI > 0.2 = retraining	Semanal
Prediction drift	KS-test na distribuição de scores	p-value < 0.05	Diário
Model accuracy	Comparação com ground-truth acumulado	< 78% = alerta	Mensal

Política de Alertas

NÍVEL	CONDIÇÃO	SLA DE RESPOSTA
CRITICAL	Accuracy < 78% · Latência P95 > 1s · API down	Imediato — rollback automático
WARNING	PSI > 0.2 em feature-chave · Drift detectado	24h — agendar retreinamento
INFO	Relatório diário de performance	Review semanal

Ciclo de Retreinamento

Recomendação:

Retreinamento mensal com dados dos últimos 6 meses em janela deslizante. Validar novo modelo contra holdout antes de promover para produção. Versionamento obrigatório no MLflow.

10. Governança e Ética

Princípios de IA Responsável

PRINCÍPIO	IMPLEMENTAÇÃO	STATUS
Transparência	Model Card público, documentação de features e limitações	✓ OK
Fairness	Testado em gender e senior_citizen; class_weight balancedo	✓ OK
Privacidade	Sem PII retido; CustomerID removido do modelo	✓ OK
Accountability	MLflow tracking de todos os experimentos; versão rastreável	✓ OK
Segurança	Validação Pydantic na API; sem injeção de dados brutos	✓ OK
LGPD/Compliance	Dados anonimizados; sem retenção de PII em logs	⚠ Verificar

Papéis e Responsabilidades

PAPEL	RESPONSABILIDADE
Data Science	Treinamento, validação, análise de bias, documentação técnica
Product Manager	Definição de SLOs, comunicação com stakeholders, priorização de retraining
DevOps / MLOps	Infraestrutura, CI/CD, monitoramento, resposta a incidentes
Legal / Compliance	LGPD, consentimento para uso de dados, auditoria de fairness

Histórico de Versões

VERSÃO	DATA	MUDANÇA PRINCIPAL
1.0.0	2026-03	EDA + Baselines (LogReg, RF, Dummy) — com data leakage
1.5.0	2026-04	MLP PyTorch adicionado (Etapa 2)
2.0.0	2026-04	Correção crítica de data leakage · FastAPI v2 · 135 testes · Monitoring